AIRLAB Alım Görevi 2026

Bölüm I: AI Temelleri

Soru 1: Benchmark ile gerçek dünya farkı

Bir modelin test setinde %96 doğruluk alıp gerçek dünyada çökmesinin olası üç nedeni şunlardır:

- **Veri Dağılımı Kayması (Domain/Data Shift):** Laboratuvar ortamındaki verinin istatistiksel dağılımı ile gerçek dünyadaki verinin (ışık, cihaz farklılığı vb.) istatistiksel dağılımının birbirinden farklı olması [1].
- **Veri Sızıntısı (Data Leakage):** Eğitim esnasında test setine ait bilgilerin sızması sonucu, modelin nesneyi değil arka plan örüntülerini ezberlemesi.
- **Aşırı Öğrenme (Overfitting):** Modelin eğitim setindeki spesifik detayları ve gürültüyü ezberleyip yeni verilere yönelik genelleme yeteneğini kaybetmesi [2].

Test Yöntemi: Veri dağılımı kaymasını test etmek için temiz test setine kontrollü yapay bozulmalar (farklı seviyelerde bulanıklık, parlaklık değişimi, sentetik gürültü) eklenerek bir "stres testi" uygulanır. Performans bu bozulmuş verilerde keskin şekilde düşüyorsa model genelleme yapamıyor demektir.

Soru 2: Şüpheli yüksek skor

Problem ve Tehlikesi: Normalizasyonun tüm veri setine (eğitim ve test) aynı anda uygulanması tipik bir **Veri Sızıntısı (Data Leakage)** hatasıdır. Bu işlem, test setinin ortalama ve standart sapma gibi istatistiksel özelliklerinin gizlice eğitim aşamasına sızmasına yol açar. Model test verisinden kopya çektiği için başarı yapay olarak %99'a çıkar. Ancak gerçek dünyada yepyeni veriler geldiğinde referans noktaları değişeceği için modelin performansı çöker [3].

Somut Kontrol Yöntemi: Veri ön işleme kodları denetlenir. Normalizasyon fonksiyonunun (örneğin `StandardScaler`) `.fit()` metodunun sadece ve sadece eğitim setine (`X_train`) uygulandığı teyit edilir. Test seti yalnızca eğitim setinden öğrenilen parametrelerle `.transform()` işleminden geçirilmelidir.

Soru 3: Veri bölme ve metrik

Train / Validation / Test Ayrımı: Dengesiz kümelerde **Tabakalı Örnekleme (Stratified Split)** yöntemi kullanılmalıdır. Veri rastgele bölünürse %10'luk azınlık sınıfı test setine hiç düşmeyebilir veya tamamen bir kümeye yığılabilir. Tabakalı bölme, veri setindeki orijinal %90/%10 sınıf oranının tüm alt kümelerde istatistiksel olarak eşit kalmasını garanti eder [1].

Doğruluğun Yanıltıcılığı ve Yeni Metrikler: Dengesiz verilerde doğruluk (accuracy) *Doğruluk Paradoksuna* neden olur. Model hiçbir patern öğrenmeyip tüm örneklere doğrudan çoğunluk sınıfı (%90) etiketini atasa bile matematiksel olarak %90 oranında başarılı görünür. Bunun yerine; azınlık sınıfını yakalama yeteneğini ölçen **Duyarlılık (Recall)**, doğru tahminlerin ne kadarının gerçekten o sınıfa ait olduğunu ölçen **Kesinlik (Precision)** ve bu ikisinin dengeli bir özeti olan **F1-Skoru** kullanılmalıdır [1].

Soru 4: Eğitim eğrisini okuma

Ne Oluyor: Model **Aşırı Öğrenme (Overfitting)** aşamasına geçmiştir. Eğitim kaybının (training loss) düşmeye devam etmesi modelin mevcut veriyi ezberlediğini, validasyon kaybının (validation loss) artmaya başlaması ise modelin genelleme yeteneğini kaybettiğini kanıtlar [2].

3 Müdahale ve Sırası:

1. **Erken Durdurma (Early Stopping):** En az maliyetli çözümdür. Validasyon kaybının minimum olduğu ve yeniden artmaya başladığı adımda (epoch) eğitim derhal durdurulur.
2. **Düzenlileştirme ve Veri Çoğaltma (Regularization & Augmentation):** İlk adım yeterli gelmezse modele Dropout katmanları eklenir, ağırlık çürümesi (L2 kısıtlaması) uygulanır veya mevcut veri seti yapay olarak (döndürme, renk değiştirme vb.) çeşitlendirilerek modelin ezber yapması fiziksel olarak zorlaştırılır.
3. **Model Karmaşıklığını Azaltma:** Yukarıdaki adımlar sorunu çözmüyorsa modelin öğrenme kapasitesi eldeki veriye göre gereksiz büyüktür. Ağdaki katman ve nöron sayıları düşürülerek mimari küçültülür [2].

Kaynakça

- Alpaydın, E. (2011). *Makine Öğrenmesi*. Boğaziçi Üniversitesi Yayınevi. (Soru 1 ve Soru 3: Veri dağılımı kayması, tabakalı örnekleme, sınıf dengesizliğinde metrik seçimi).
- Goodfellow, I., Bengio, Y., & Courville, A. (2018). *Derin Öğrenme*. (Çev. Ed. M. A. Şahin). Buzdağı Yayınevi. (Soru 1 ve Soru 4: Aşırı öğrenme belirtileri, kapasite küçültme, erken durdurma ve dropout yöntemleri).
- Kuhn, M., & Johnson, K. (2013). *Uygulamalı Öngörüsel Modelleme (Applied Predictive Modeling)*. Springer. (Soru 2: Veri sızıntısı analizi ve ön işleme aşamasında izolasyon kuralları).